## ACM

## February 5, 2021

```
In [2]: #chargement des donnees - index_col = 0 pour indiquer que la colonne n\u00e40 est un label
        import pandas
        D = pandas.read_excel("ACM.xlsx",sheet_name="ACM",index_col=0)
In [3]: #affichage des caracteristiques
        print(D.info())
<class 'pandas.core.frame.DataFrame'>
Index: 8 entries, Beauceron to Labrador
Data columns (total 3 columns):
Taille
             8 non-null object
Velocite
             8 non-null object
Affection
             8 non-null object
dtypes: object(3)
memory usage: 256.0+ bytes
None
In [5]: #recuperation des variables actives
        DActives = D[['Taille', 'Velocite', 'Affection']]
        print(DActives)
               Taille Velocite Affection
Chien
Beauceron
             Taille++ Veloc++
                                  Affec+
Basset
               Taill-
                         Velo-
                                   Affe-
Berger-All
             Taille++ Veloc++
                                  Affec+
Boxer
              Taille+
                        Veloc+
                                  Affec+
Bull-Dog
               Taill-
                        Velo-
                                  Affec+
Bull-Mastif Taille++
                                  Affe-
                         Velo-
Caniche
                        Veloc+
                                  Affec+
               Taill-
Labrador
              Taille+
                        Veloc+
                                  Affec+
In [6]: #recuperation des infos -
        #nombre de variables
        p = DActives.shape[1]
```

#nombre d'observations
n = DActives.shape[0]

```
In [7]: #codage en 0/1 les noms de modalites sont explicites
        #pas necessaire de prefixer les indicatrices par les noms de variables
        X = pandas.get_dummies(DActives,prefix='',prefix_sep='')
        print(X)
             Taill- Taille+ Taille++ Velo- Veloc+ Veloc++ Affe- Affec+
Chien
Beauceron
                            0
                                             0
                                                     0
                                                                      0
                  0
                                                               1
                                      1
                                                                               1
Basset
                  1
                            0
                                      0
                                             1
                                                     0
                                                               0
                                                                      1
                                                                              0
Berger-All
                  0
                            0
                                             0
                                                     0
                                                               1
                                                                      0
                                      1
                                                                               1
Boxer
                  0
                            1
                                      0
                                             0
                                                     1
                                                               0
                                                                      0
                                                                               1
Bull-Dog
                            0
                                      0
                                                               0
                                                                      0
                                             1
                                                     0
                                                                               1
Bull-Mastif
                  0
                            0
                                      1
                                             1
                                                     0
                                                               0
                                                                              0
Caniche
                            0
                                      0
                                             0
                                                     1
                                                               0
                                                                      0
                  1
                                                                              1
Labrador
                  0
                            1
                                      0
                                             0
                                                     1
                                                               0
                                                                      0
                                                                               1
In [9]: #librairie numpy
        import numpy
        #profil individu moyen
        ind_moy = numpy.sum(X.values,axis=0)/(n*p)
        print(ind_moy)
[ 0.125
              0.08333333 0.125
                                       0.125
                                                   0.125
                                                                0.08333333
  0.08333333 0.25
                        1
In [11]: #distance du KHI-2 entre beauceron (nř0) et basset (nř1)
         print(numpy.sum(1/ind_moy*(X.values[0,:]/p-X.values[1,:]/p)**2))
         #idem entre basset(n\check{r}1) et caniche(n\check{r}6)
         print(numpy.sum(1/ind_moy*(X.values[1,:]/p-X.values[6,:]/p)**2))
5.777777778
3.555555556
In [13]: #distance a l'origine du basset (nř1)
         print(numpy.sum(1/ind_moy*(X.values[1,:]/p-ind_moy)**2))
         #distance a l'origine du caniche (nř6)
         print(numpy.sum(1/ind_moy*(X.values[6,:]/p-ind_moy)**2))
2.11111111111
1.222222222
In [14]: #distance a l'origine des individus (obs.)
         disto_ind = numpy.apply_along_axis(arr=X.values,axis=1,func1d=lambda x:numpy.sum(1 /i
```

#poids des obs.

```
poids_ind = numpy.ones(X.shape[0])/n
         #inertie
         inertie_ind = poids_ind*disto_ind
         #afffichage
        print(pandas.DataFrame(numpy.transpose([poids_ind,disto_ind,inertie_ind]),index=D.index
         #poids (1/n), leurs distances a lorigine, leurs inerties [1/2()]
                 0
                                    2
                           1
Chien
Beauceron
            0.125 1.666667 0.208333
Basset
            0.125 2.111111 0.263889
Berger-All 0.125 1.666667 0.208333
Boxer
            0.125 1.666667 0.208333
Bull-Dog
            0.125 1.222222 0.152778
Bull-Mastif 0.125 2.111111 0.263889
Caniche
            0.125 1.222222 0.152778
Labrador
            0.125 1.666667 0.208333
In [15]: #inerrie totale
         inertie_tot_ind = numpy.sum(inertie_ind)
        print(inertie_tot_ind)
1.6666666667
In [ ]: #Linformation totale portee par les donnees, comptabilisee via les distances entre ind
In [ ]: # 2 Analyse des associations entre les modalites
In [ ]: #Distance entre modalites
In [17]: #somme en colonne
        somme_col = numpy.sum(X.values,axis=0)
        print(somme_col)
[3 2 3 3 3 2 2 6]
In [78]: # avec les listes , slicing ne fonctionne pas
        M = [[1,2,3],[4,5,6],[7,8,9]]
        M[: , 0]
                                                 Traceback (most recent call last)
        TypeError
        <ipython-input-78-57336eea6fa7> in <module>()
```

```
1 # avec les listes , slicing ne fonctionne pas
          2 M=[[1,2,3],[4,5,6],[7,8,9]]
    ----> 3 M[: , 0]
        TypeError: list indices must be integers or slices, not tuple
In [76]: # on doit travailler avec array (Tableau) ( ca marche tres bien)
         M=numpy.array([[1,2,3],[4,5,6],[7,8,9]])
         M[: , 0]
Out[76]: array([1, 4, 7])
In [18]: #distance entre taille- (2) et velocite- (5)
         print(numpy.sum(n*((X.values[:,2]/somme_col[2]-X.values[:,5]/somme_col[5])**2)))
1.33333333333
In [19]: #distance entre taille- (2) et velocite+ (3)
         print(numpy.sum(n*((X.values[:,2]/somme_col[2]-X.values[:,3]/somme_col[3])**2)))
3.555555556
In [ ]: #Distance a lorigine
In [21]: #profil moyen des variables-modalites
         moda_moy = numpy.ones(X.shape[0])/n
         #distance a l'origine taille-
         print(numpy.sum(n*((X.values[:,0]/somme_col[0]-moda_moy)**2)))
1.6666666667
In [22]: #distance a l'origine taille+
         print(numpy.sum(n*((X.values[:,1]/somme_col[1]-moda_moy)**2)))
3.0
In [ ]: #Inertie totale
In [25]: #poids des variables_modalites (points modalites)
         poids_moda = somme_col/(n*p)
         #distance a l'origine des points modalites
         disto_moda = numpy.apply_along_axis(arr=X.values/somme_col,axis=0,func1d=lambda x: num
         #inertie
         inertie_moda = poids_moda * disto_moda
         #affichage
         print(pandas.DataFrame(numpy.transpose([poids_moda,disto_moda,inertie_moda]),index =X
```

```
Inertie
            Poids
                     Disto
Taill-
         0.125000 1.666667 0.208333
Taille+
         0.083333 3.000000 0.250000
Taille++
         0.125000 1.666667
                            0.208333
Velo-
         0.125000 1.666667
                            0.208333
Veloc+
         0.125000 1.666667 0.208333
Veloc++
         0.083333 3.000000 0.250000
Affe-
         0.083333 3.000000 0.250000
Affec+
         0.250000 0.333333 0.083333
```

## In [ ]: #Remarque

#La valeur de linertie totale obtenue via le point de vue des modalites est strictemen #exprimee a partir de lanalyse des proximites entre les individus .

#Nous avons deux manieres dapprehender les donnees, mais il sagit bien des memes donne #Nous constatons de surcroit que les modalites (Taille+, Veloc++, Affec-) sont celles #contribuent le plus a linformation globale.

In [27]: #inertie totale des points-modalites
 inertie\_tot\_moda = numpy.sum(inertie\_moda)
 print(inertie\_tot\_moda)

## 1.6666666667

Basset

Boxer

Berger-All

In [24]: #ACM via une ACP sur le tableau des profils

In []: #Nous reduisons les variables par la racine carree de leur variance c.-a-d. lecart-typ

	Taill-	Taille+	Taille++	Velo-	Veloc+	Veloc++	\
Chien							
Beauceron	0.000000	0.000000	0.333333	0.000000	0.000000	0.333333	
Basset	0.333333	0.000000	0.000000	0.333333	0.000000	0.000000	
Berger-All	0.000000	0.000000	0.333333	0.000000	0.000000	0.333333	
Boxer	0.000000	0.333333	0.000000	0.000000	0.333333	0.000000	
Bull-Dog	0.333333	0.000000	0.000000	0.333333	0.000000	0.000000	
Bull-Mastif	0.000000	0.000000	0.333333	0.333333	0.000000	0.000000	
Caniche	0.333333	0.000000	0.000000	0.000000	0.333333	0.000000	
Labrador	0.000000	0.333333	0.000000	0.000000	0.333333	0.000000	
	Affe-	Affec+					
Chien							
Beauceron	0.000000	0.333333					

0.333333 0.000000

0.000000 0.333333

```
Bull-Mastif 0.333333 0.000000
Caniche
             0.000000 0.333333
Labrador
             0.000000 0.333333
In [30]: #Nous reduisons les variables par la racine carree de leur variance c.-a-d. lecart-ty
         #reduire les profils
        profil = profil/numpy.std(profil,axis=0,ddof=0)
        print(profil)
[[ 0.
               0.
                           2.06559112 0.
                                                   0.
                                                               2.30940108
               2.30940108]
 [ 2.06559112 0.
                                       2.06559112 0.
                           0.
  2.30940108 0.
                        ]
 ΓО.
                           2.06559112 0.
               0.
                                                   0.
                                                               2.30940108
  0.
               2.30940108]
                                                   2.06559112 0.
 ΓΟ.
               2.30940108 0.
                                       0.
                                                                           0.
  2.30940108]
 Γ 2.06559112 O.
                           0.
                                       2.06559112 0.
                                                                           0.
                                                               0.
  2.30940108]
 ΓО.
               0.
                           2.06559112 2.06559112 0.
                                                               0.
  2.30940108 0.
                         1
 [ 2.06559112 0.
                           0.
                                       0.
                                                   2.06559112 0.
                                                                           0.
  2.30940108]
 [ 0.
               2.30940108 0.
                                       0.
                                                   2.06559112 0.
                                                                           0.
  2.30940108]]
In [31]: #ponderation des modalites
        pond_moda = (n-somme_col)/(n*p)
        print(pond_moda)
[ 0.20833333  0.25
                         0.20833333  0.20833333  0.20833333  0.25
                                                                          0.25
  0.083333331
In [32]: #appliquer la ponderation aux profils
        profil = profil*numpy.sqrt(pond_moda)
        print(profil)
[[ 0.
               0.
                           0.94280904 0.
                                                   0.
                                                               1.15470054
               0.66666667]
  0.
 [ 0.94280904 0.
                           0.
                                       0.94280904 0.
                                                               0.
  1.15470054 0.
                         ]
 ΓΟ.
               0.
                           0.94280904 0.
                                                   0.
                                                               1.15470054
  0.
               0.666666671
 Γ0.
               1.15470054 0.
                                       0.
                                                   0.94280904 0.
                                                                           0.
  0.66666667]
```

Bull-Dog

0.000000 0.333333

```
[ 0.94280904 0.
                           0.
                                       0.94280904 0.
                                                               0.
                                                                           0.
  0.66666667]
 [ 0.
                           0.94280904 0.94280904 0.
                                                               0.
               0.
                         1
   1.15470054 0.
 [ 0.94280904 0.
                           0.
                                       0.
                                                   0.94280904 0.
                                                                           0.
  0.66666667]
               1.15470054 0.
                                       0.
                                                   0.94280904 0.
                                                                            0.
  0.66666667]]
In []: #numpy.linalg.eig
In [35]: R=numpy.corrcoef(X.values,rowvar=False)
In [36]: pr=numpy.linalg.eig(R)
         print(pr)
(array([ 3.56910019e+00,
                            2.65189894e+00,
                                              1.27835795e+00,
        -1.50908880e-16,
                           3.40048343e-01,
                                             1.60594584e-01,
                           0.00000000e+00]), array([[ -1.97572068e-01,
                                                                         3.51721627e-01,
                                                                                            6.3
         7.53627951e-17,
         -5.97614305e-01.
                            2.23488183e-01.
                                              1.75104646e-01,
          5.30093358e-02,
                            3.01605041e-17],
       [ 3.62565037e-01,
                            2.39130868e-01, -4.89295285e-01,
         -5.34522484e-01, -3.89068180e-01,
                                              3.67239448e-01,
          4.74129913e-02,
                            6.69823572e-17],
       [-1.26715960e-01, -5.65606777e-01, -1.94425636e-01,
         -5.97614305e-01,
                            1.24504976e-01,
                                            -5.03573594e-01,
          5.30093358e-02,
                           -4.71717356e-17],
       [-4.71079787e-01,
                            1.79135691e-01,
                                              2.21190999e-02,
          4.00891461e-16,
                           -5.77583745e-01,
                                             -2.34006718e-01,
         -5.95258656e-01,
                           -1.51851997e-17],
       [ 3.96335443e-01,
                            3.37794725e-01, -1.64530188e-01,
                            5.10772644e-01,
                                             -2.89328891e-01,
          1.14945139e-16,
         -5.95258656e-01,
                           -2.94097915e-17],
       [ 8.35667175e-02,
                           -5.77945774e-01,
                                              1.59220436e-01,
         -1.24706289e-15,
                            7.46970818e-02,
                                              5.85106998e-01,
         -5.32415528e-01,
                            5.76014892e-17],
       [ -4.62316770e-01,
                            9.74194769e-02, -3.67676828e-01,
         -4.65480057e-16,
                            3.02577398e-01,
                                              2.23681287e-01,
          1.84450459e-16,
                            7.07106781e-01],
       [ 4.62316770e-01, -9.74194769e-02,
                                              3.67676828e-01,
                           -3.02577398e-01, -2.23681287e-01,
          4.65480057e-16,
          9.59407461e-17,
                            7.07106781e-01]]))
In [38]: t=sorted(pr[0],reverse=True)
         v=t/sum(t)
```

w=numpy.cumsum(v)

```
t=[t,v,w]
        print(pandas.DataFrame(numpy.transpose(t),columns=['Val.P', '%','cumsum %'],index=range
                           % cumsum %
         Val.P
0 3.569100e+00 4.461375e-01 0.446138
1 2.651899e+00 3.314874e-01 0.777625
2 1.278358e+00 1.597947e-01 0.937420
3 3.400483e-01 4.250604e-02 0.979926
4 1.605946e-01 2.007432e-02 1.000000
5 7.536280e-17 9.420349e-18 1.000000
6 0.000000e+00 0.000000e+00 1.000000
7 -1.509089e-16 -1.886361e-17 1.000000
In [ ]: #LACP ne sait pas quil y a des redondances artificielles dans les
        #donnees, dou les facteurs aux variances nulles en excedent.
In [40]: #coordonnees fact. des observations (1er plan)
        print(pandas.DataFrame(pr[1][:,:2],index=X.index,columns=['Fact.1','Fact.2']))
              Fact.1
                        Fact.2
Chien
Beauceron
           -0.197572 0.351722
Basset
           0.362565 0.239131
Berger-All -0.126716 -0.565607
Boxer
           -0.471080 0.179136
Bull-Dog
            0.396335 0.337795
Bull-Mastif 0.083567 -0.577946
Caniche
           -0.462317 0.097419
Labrador
            0.462317 -0.097419
```